

Étude générale du projet

18 avril 2026

ÉTUDE GÉNÉRALE DU PROJET

Introduction

Ce chapitre est consacré pour situer le projet dans son contexte général. Pour ce faire, nous énonçons le cadre du projet et nous présentons l'organisme d'accueil «DECADE» ainsi que la problématique qui nous a été proposée. Nous abordons aussi la méthodologie adoptée pour la gestion du travail à réaliser.

1.1 Problématique

Dans un environnement e-commerce de plus en plus concurrentiel, la capacité à proposer des services pertinents et hautement personnalisés constitue aujourd'hui un levier stratégique essentiel de différenciation et de performance. Parmi ces services, les systèmes de recommandation occupent une place centrale. Ils ne se limitent plus à de simples outils d'aide à la navigation, mais deviennent de véritables moteurs de croissance, influençant directement des indicateurs clés tels que le taux de conversion, le panier moyen, la fidélisation client ainsi que l'engagement utilisateur.

Dans le contexte spécifique de La Foir'Fouille, une chaîne de magasins française spécialisée dans le maxidiscount d'équipement pour la maison et qui est cliente de DECADE depuis 2014, cette problématique est encore plus marquée en raison de plusieurs caractéristiques métier et techniques, notamment :

- un catalogue produit fortement saisonnier, nécessitant des recommandations dynamiques et contextuelles ;
- une stratégie omnicanale intégrant à la fois les canaux web et magasin ;
- une architecture moderne de type headless, favorisant la flexibilité mais augmentant la complexité de personnalisation en temps réel.

Ainsi, il devient indispensable de concevoir et de mettre en place un système de recommandation intelligent, capable de comprendre le contexte utilisateur en temps réel (comportement, historique, saisonnalité, contraintes métier) et de générer des suggestions pertinentes, cohérentes et adaptées aux objectifs business de l'entreprise.

1.2 Objectifs du projet

Dans le cadre de la gestion de l'expérience utilisateur et la personnalisation des services dans le secteur e-commerce, DECADE souhaite concevoir et intégrer une solution de recommandation de produits au sein du site e-commerce « La Foir'Fouille ».

L'objectif de ce projet est de concevoir et réaliser une solution capable de proposer, en temps réel ou quasi-temps réel, des recommandations de produits personnalisées et contextuelles à chaque

utilisateur, tout au long de son parcours client. Le projet doit répondre à des enjeux de performance, de personnalisation et d'expérience utilisateur, avec pour finalité d'augmenter le taux de conversion, d'encourager la vente croisée et de fidéliser les visiteurs sur le site.

1.3 Étude de l'existant

Dans le cadre de cette étude, nous commençons par exposer les solutions existantes des moteurs de recommandation des sites web de e-commerce. Puis, nous focalisons sur les limites de la solution actuelle adoptée par le site La Foir'Fouille.

1.3.1 Solutions existantes

De nombreuses solutions de recommandation e-commerce se distinguent par leurs approches innovantes, intégrant des fonctionnalités avancées telles que la personnalisation comportementale, le filtrage collaboratif et la contextualisation des suggestions tout au long du parcours client. Ces fonctionnalités permettent non seulement d'améliorer la pertinence des recommandations, mais aussi d'augmenter le taux de conversion et de fidéliser les utilisateurs.

Dans le cadre de cette analyse, nous distinguons deux catégories de solutions : la solution actuellement en production sur le site de La Foir'Fouille, et les solutions basées sur l'intelligence artificielle envisagées comme alternative.

a. Solution actuelle : BEyable

BEyable est la solution de personnalisation actuellement utilisée par La Foir'Fouille. Il s'agit d'une plateforme française de recommandation e-commerce qui assure l'affichage des top ventes, des top ajouts au panier, ainsi qu'une logique de recommandation par magasin de rattachement. Son intégration repose sur une injection JavaScript côté client (*client-side rendering*), ce qui lui permet d'être déployée rapidement sans modification du backend. Toutefois, cette approche ne repose pas sur l'intelligence artificielle : elle est entièrement fondée sur des règles métier prédéfinies, sans capacité d'apprentissage ni de personnalisation dynamique basée sur le comportement utilisateur.

Limites de BEyable

1. **Impact SEO :** BEyable repose sur une injection JavaScript côté client, ce qui empêche les moteurs de recherche d'indexer correctement les recommandations dans le cadre de l'architecture headless Next.js de La Foir'Fouille. Cette approche *client-side* nuit directement au référencement naturel du site et s'avère incompatible avec les exigences d'une plateforme moderne orientée performance.

2. **Absence d'internationalisation** : Les prix ne sont affichés qu'en euro, sans aucune adaptation aux devises locales, ce qui constitue un frein direct à toute expansion internationale de La Foir'Fouille.
3. **Absence de flexibilité métier** : BEyable impose ses propres règles de recommandation, privant La Foir'Fouille de toute maîtrise sur les exclusions, priorisations et contextualisations spécifiques à son activité.
4. **Non-scalabilité multi-sites** : Cette dépendance vis-à-vis du fournisseur se traduit directement par une non-scalabilité structurelle : l'extension du site vers Snoop implique la souscription d'un nouveau contrat, avec des règles et des contraintes imposées par BEyable, rendant toute évolution multi-sites coûteuse, rigide et non maîtrisée.
5. **Coût élevé** : BEyable engendre un coût d'abonnement annuel récurrent, auquel s'ajoutent des frais supplémentaires à chaque modification des règles de personnalisation. Ce modèle de facturation s'avère disproportionné au regard des fonctionnalités offertes, qui demeurent limitées et entièrement basées sur des règles métier prédéfinies, sans aucune capacité d'apprentissage automatique.

Face aux limites de BEyable, et dans l'optique de doter La Foir'Fouille d'un véritable moteur de recommandation basé sur l'intelligence artificielle, nous avons analysé les solutions du marché les plus pertinentes dans ce domaine.

b. Recombee

Recombee est une solution de recommandation as a service fondée en 2015 à Prague, orientée vers les plateformes e-commerce, médias et contenus numériques. Elle repose sur des algorithmes d'intelligence artificielle entraînés en temps réel sur les interactions utilisateurs, permettant de générer des recommandations personnalisées dès le premier clic. Sa conception API-first et la disponibilité de SDKs dans plusieurs langages en font une solution techniquement accessible, adoptée par des plateformes telles que Tripadvisor, DAZN et 9GAG.

c. Dynamic Yield

Dynamic Yield, acquis par Mastercard, est une plateforme entreprise de personnalisation et de recommandation reconnue comme Leader dans le Gartner Magic Quadrant pendant huit années consécutives. Elle propose des algorithmes avancés de *deep learning* et de *reinforcement learning*, permettant de personnaliser l'ensemble du parcours client en temps réel. Elle couvre un large spectre de cas d'usage : recommandations produits, segmentation comportementale, tests A/B, orchestration de parcours et personnalisation omnicanale. Sa tarification, disponible uniquement sur devis, la positionne exclusivement sur le segment entreprise.

1.3.2 Critères de comparaison

Afin d'évaluer ces solutions dans le contexte spécifique de La Foir'Fouille, plusieurs critères ont été retenus :

- **Pertinence des recommandations** : capacité à proposer des produits adaptés au contexte et aux besoins réels de l'utilisateur, en tenant compte de son intention d'achat et de son parcours de navigation.
- **Personnalisation** : prise en compte du comportement utilisateur, de l'historique d'achat et du contexte spécifique à La Foir'Fouille, notamment le magasin de rattachement et la saisonnalité des produits.
- **Flexibilité métier** : possibilité pour La Foir'Fouille de configurer et de contrôler ses propres règles de recommandation — exclusions, priorisations, disponibilité — sans dépendre des paramètres imposés par le fournisseur.
- **Coût** : coût total d'intégration et d'exploitation, incluant les abonnements, la facturation à l'usage et les coûts liés à l'extension vers de nouveaux sites.
- **Intégration technique** : compatibilité avec l'architecture existante de La Foir'Fouille, notamment SAP Commerce, les APIs OCC et le frontend Next.js headless.

1.3.3 Tableau comparaison des solutions IA existantes

Critère	Recombee	Dynamic Yield
Pertinence des recommandations	✓ Avancée (filtrage collaboratif, content-based, modèles hybrides en temps réel)	✓ Très avancée (<i>deep learning, reinforcement learning</i>)
Personnalisation	✓ Complète (comportement utilisateur, historique, attributs produits)	✓ Complète (comportement, CRM, données magasin, météo)
Flexibilité métier	✓ Configurable via ReQL (filtres, boosters, contraintes paramétrables)	~ Limitée par la plateforme (règles via interface propriétaire)
Scalabilité	~ Par paliers tarifaires (surcoût à chaque nouveau site ou dépassement de quota)	~ Entreprise, surcoût contractuel pour chaque extension
Coût	~ À partir de 99\$/mois (Standard), jusqu'à 2 499\$/mois (Premium), facturation par requête au-delà	✗ Très élevé, sur devis uniquement, segment entreprise
Intégration technique	✓ API REST + SDKs disponibles, intégration via appel serveur possible (SSR)	~ Via API générique, pas de connecteur natif SAP Commerce

TABLE 1.1 – Comparaison des solutions IA existantes — Recombee vs Dynamic Yield

1.4 Solution proposée

Face aux limites identifiées, le développement d'un moteur de recommandation interne personnalisé constitue une opportunité stratégique. La solution proposée vise à combiner la puissance de l'intelligence artificielle, la flexibilité des règles métier et une intégration native à l'architecture existante.

Elle permettra notamment :

- une personnalisation avancée basée sur le comportement utilisateur ;

- une adaptation contextuelle (magasin, saisonnalité, stock);
- une amélioration du SEO grâce au rendu serveur (SSR);
- une réduction des coûts à long terme;
- une scalabilité naturelle vers de nouveaux projets.

1.5 Analyse des solutions proposées pour le système de recommandation

1.5.1 Présentation du contexte

Dans le cadre du développement du moteur de recommandation pour la plateforme e-commerce **La Foir’Fouille**, géré par **DECADE Tunisie**, nous avons conduit une étude comparative approfondie des approches algorithmiques disponibles. Le système doit répondre à des contraintes techniques strictes : un catalogue de **524 023 produits**, une latence maximale de **100 ms** par requête, et une scalabilité native vers plusieurs sites (Snoop, etc.).

L’analyse porte sur cinq fonctionnalités de recommandation distinctes, chacune répondant à un contexte d’usage précis. Pour chaque fonctionnalité, plusieurs options algorithmiques ont été évaluées avant de sélectionner la solution la plus adaptée.

1.5.2 Classification des approches de recommandation

Les systèmes de recommandation se répartissent en quatre grandes familles théoriques, toutes mobilisées dans ce projet :

TABLE 1.2 – Classification des approches de recommandation utilisées

Famille	Principe	Usage dans le projet
Popularity-based	Même résultat pour tous les utilisateurs, basé sur la popularité collective	Top ventes, top ajout panier, top par catégorie
Content-based	Analyse des attributs intrinsèques du produit pour trouver des articles similaires	Similarité produit sur la fiche produit
Collaborative (item-based)	Basé sur les comportements collectifs d'achat (paniers partagés)	Cross-sell sur la fiche produit
Hybride	Combinaison de plusieurs approches pour compenser leurs faiblesses respectives	Top ventes personnalisé (utilisateur connecté)

1.5.3 Recommandation 1 — Similarité produit (Fiche Produit)

1.5.3.1 Objectif

Afficher sur la fiche produit les articles les plus similaires à celui consulté, afin de faciliter la découverte d'alternatives pertinentes. La contrainte de volumétrie (524 023 produits) impose une approche précalculable et scalable.

1.5.3.2 Comparaison des approches

TABLE 1.3 – Évaluation comparative des approches de similarité produit

Critère	Similarité cosinus (attributs)	Sentence-Transformers (NLP)	Hybride
Complexité	Très faible	Moyenne	Moyenne+
Compréhension sémantique	Absente	Excellente	Excellente
Scalabilité 524K	Précalcul nécessaire	Via FAISS (<10ms)	Via FAISS (<10ms)
Cold start produit	Aucun problème	Fonctionne	Aucun problème
Robustesse	Bonne	Bonne	Maximale

1.5.3.3 Solution retenue

Option retenue : Approche hybride combinant la similarité cosinus sur les attributs structurés SAP et les embeddings sémantiques produits par le modèle `paraphrase-multilingual-MiniLM` (HuggingFace), avec indexation vectorielle via **FAISS**.

Justification : FAISS (Facebook AI Similarity Search) est indispensable pour maintenir une latence inférieure à 10 ms sur un index de 524 023 vecteurs. La combinaison des attributs structurés (catégorie, prix, marque) et des embeddings sémantiques maximise la pertinence des recommandations tout en assurant la robustesse en cas d'absence de description textuelle (cold start produit).

1.5.4 Recommandation 2 — Cross-sell (Fiche Produit)

1.5.4.1 Objectif

Identifier et afficher, sur la fiche d'un produit, les articles fréquemment achetés conjointement. Cette approche exploite les historiques de paniers issus de SAP Commerce pour détecter des associations statistiquement significatives (ex : une table achetée avec des chaises).

1.5.4.2 Comparaison des approches

TABLE 1.4 – Évaluation comparative des approches cross-sell

Critère	Co-occurrence brute	ALS (Factorisation matricielle)	FP-Growth + Lift
Complexité	Très faible	Élevée	Moyenne
Biais popularité	Fort	Non corrigé	Corrigé par le lift
Cold start utilisateur	Aucun	Problème majeur	Aucun
Interprétabilité	Bonne	Faible	Excellente
Pertinence	Moyenne	Très bonne	Bonne à très bonne

1.5.4.3 Solution retenue

Option retenue : Algorithme **FP-Growth** (Frequent Pattern Growth) avec mesure de **lift**, implémenté via la bibliothèque `mlxtend`.

Justification : Le lift corrige le biais inhérent aux produits à fort volume de vente, qui tendent à co-apparaître artificiellement avec l'ensemble du catalogue. Un lift supérieur à 1 garantit que l'association détectée est statistiquement significative et non fortuite. Les règles générées (*si table, alors chaise, lift = 2,3*) sont directement interprétables et validables par l'équipe métier. L'approche item-based est également indépendante de l'identité de l'utilisateur, ce qui la rend applicable aux visiteurs anonymes.

1.5.5 Recommandation 3 — Top ventes (Page d'accueil, Liste, Carte)

1.5.5.1 Objectif

Afficher les produits les plus populaires sur la page d'accueil (global et par magasin), dans les pages de liste (tri) et dans les cartes produit (top ajout panier). Ces recommandations sont non personnalisées et doivent refléter les tendances en temps quasi-réel.

1.5.5.2 Comparaison des approches

TABLE 1.5 – Évaluation comparative des approches de calcul des top ventes

Critère	Agrégation SQL pure	Time-decay	Score multi- signaux
Pondération temporelle	Absente	Excellente	Excellente
Détection de tendances	Aucune	Bonne	Très bonne
Données requises	Commandes unique- ment	Commandes unique- ment	Commandes + vues + paniers
Adaptation saisonnière	Non adaptée	Adaptée	Adaptée
Complexité	Très faible	Faible	Moyenne (risque si données man- quantes)

1.5.5.3 Solution retenue

Option retenue : Score avec **décroissance temporelle (time-decay)**, inspiré de l’algorithme de scoring Hacker News.

Justification : Le catalogue La Foir’Fouille est fortement saisonnier. Sans pondération temporelle, les best-sellers historiques domineraient en permanence, empêchant les nouvelles tendances de remonter dans les recommandations. La formule de décroissance est mathématiquement justifiable, facile à calibrer via le paramètre *gravity*, et ne requiert aucune source de données additionnelle au-delà de l’historique de commandes SAP.

1.5.6 Recommandation 4 — Top ventes personnalisé (utilisateur connecté)

1.5.6.1 Objectif

Adapter dynamiquement les recommandations de la page d’accueil au profil de l’utilisateur connecté, tout en gérant élégamment le cas du cold start (utilisateur avec peu ou pas d’historique d’achat).

1.5.6.2 Comparaison des approches

TABLE 1.6 – Évaluation comparative des approches de personnalisation

Critère	Filtrage par catégories	Switching hybride (seuil)	Weighted Hybrid dynamique
Gestion du cold start	Partielle	Correcte	Parfaite
Transition global/perso	Abrupte	Abrupte	Douce et continue
Effet bulle filtre	Fort	Moyen	Faible
Complexité	Très faible	Faible	Moyenne
Rigueur mathématique	Faible	Faible	Très forte

1.5.6.3 Solution retenue

Option retenue : Weighted Hybrid dynamique avec coefficient α progressif, défini par :

$$\alpha = \min\left(\frac{|\text{historique_utilisateur}|}{10}, 0,7\right)$$

$$\text{score_final}(p) = (1 - \alpha) \cdot \text{score_popularité}(p) + \alpha \cdot \text{score_affinité}(p)$$

Justification : Cette formulation garantit une transition continue et mathématiquement rigoureuse entre les recommandations globales ($\alpha \approx 0$ pour un nouvel utilisateur) et les recommandations personnalisées ($\alpha \rightarrow 0,7$ au fur et à mesure des achats). Le plafond à 0,7 préserve une part de popularité globale dans tous les cas, assurant la diversité des recommandations et limitant l’effet de bulle filtre.

1.5.7 Recommandation 5 — Saisonnalité (Backoffice Admin)

1.5.7.1 Objectif

Permettre à l’administrateur de définir des périodes saisonnières (Noël, rentrée scolaire, etc.) pendant lesquelles les recommandations de la page d’accueil sont remplacées par une sélection manuelle de produits, indépendamment des algorithmes de popularité.

1.5.7.2 Solution retenue

Option retenue : Rule-based override sur critères de dates, déclenché depuis le backoffice SAP Commerce.

Justification : Ce mécanisme constitue une couche de règles métier superposée aux algorithmes de recommandation, et non un algorithme à part entière. Il offre un contrôle total à l'équipe La Foir'Fouille sur la mise en avant des produits saisonniers, de façon simple, transparente et sans dépendance envers un modèle externe. Les saisonnalités sont stockées en base de données (MySQL) avec une mise en cache Redis (TTL 5 minutes) pour respecter la contrainte de latence.

1.5.8 Récapitulatif des choix algorithmiques

TABLE 1.7 – Récapitulatif des solutions retenues par fonctionnalité

Fonctionnalité	Algorithme retenu	Justification principale
Similarité produit (FP)	Hybride : cosinus + Sentence-Transformers + FAISS	Robustesse attributs + sémantique, FAISS indispensable à 524K produits
Cross-sell (FP)	FP-Growth + mesure de lift (mlxtend)	Correction du biais popularité, règles interprétables, visiteurs anonymes
Top ventes global/magasin	Agrégation SQL + décroissance temporelle	Adapté à la forte saisonnalité du catalogue
Top ajout panier	Agrégation événements add-to-cart (SQL + Redis)	Signal distinct des ventes : mesure l'intention d'achat
Top ventes personnalisé	Weighted Hybrid dynamique (α progressif)	Transition douce cold start, personnalisation croissante avec l'historique
Saisonnalité (admin)	Rule-based override sur dates (FastAPI + MySQL)	Contrôle total, simple, transparent, maîtrisé par l'équipe métier

L'architecture proposée repose sur une combinaison réfléchie d'algorithmes classiques (*FP-Growth*, *time-decay*) et de techniques d'intelligence artificielle modernes (*Sentence-Transformers*, *FAISS*) adaptées aux contraintes spécifiques du projet : 524 023 produits, latence inférieure à 100 ms assurée par Redis, et besoins métier propres à La Foir'Fouille (saisonnalité, magasin de rattachement, conformité SEO). La solution est entièrement interne, souveraine sur les données, et scalable vers de nouveaux sites sans surcoût contractuel.

1.6 Architecture technique de la solution

L'architecture du moteur de recommandation repose sur quatre couches distinctes, chacune jouant un rôle précis dans la chaîne de traitement. La séparation entre le pipeline *batch* (traitement nocturne) et la couche temps réel est le choix fondamental qui garantit le respect de la contrainte de latence inférieure à 100 ms.




FIGURE 1.1 – Architecture en couches du moteur de recommandation

1.6.1 Flux d'une requête en temps réel

Lors de la consultation d'une fiche produit, le frontend Next.js émet une requête côté serveur (SSR) vers FastAPI. Le traitement suit la logique de cache illustrée ci-dessous.




FIGURE 1.2 – Flux d’une requête de recommandation — logique cache HIT/MISS

TABLE 1.8 – Composants de l’architecture et rôles associés

Composant	Technologie	Rôle
Frontend	Next.js (SSR)	Affichage des recommandations, conformité SEO
API	FastAPI	Orchestration, routing, logique cache
Cache	Redis	Réponses précalculées, TTL configurable
Index ANN	FAISS	Recherche vectorielle < 10 ms sur 524K vecteurs
Données	MySQL	Règles métier, saisonnalité, enrichissement
Source ERP	SAP Commerce	Catalogue, commandes, API OCC

1.7 Plan d’évaluation du système de recommandation

L’évaluation du moteur de recommandation repose sur deux catégories de métriques : les métriques *offline*, calculables sur les données historiques SAP Commerce avant tout déploiement en production, et les métriques *online*, mesurables via un dispositif de test A/B après mise en service.

1.7.1 Métriques offline

1.7.1.1 Precision@K et Recall@K

La *Precision@K* mesure la proportion de produits pertinents parmi les K recommandations retournées par le système :

$$\text{Precision@K} = \frac{|\text{items pertinents} \cap \text{top-}K|}{K} \quad (1.1)$$

Le *Recall@K* mesure la couverture des items pertinents connus dans le top- K :

$$\text{Recall@K} = \frac{|\text{items pertinents} \cap \text{top-}K|}{|\text{items pertinents}|} \quad (1.2)$$

Dans le cadre de ce projet, $K = 5$ pour la fiche produit et $K = 10$ pour la page d’accueil. Un produit est considéré pertinent s’il figure dans le même panier historique que le produit consulté (cross-sell) ou dans l’historique d’achat de l’utilisateur (top ventes personnalisé).

1.7.1.2 NDCG@K

Le *Normalized Discounted Cumulative Gain* (NDCG) pénalise les bonnes recommandations mal classées. Un produit pertinent affiché en première position contribue davantage qu’en position K :

$$\text{DCG@K} = \sum_{i=1}^K \frac{\text{rel}_i}{\log_2(i+1)}, \quad \text{NDCG@K} = \frac{\text{DCG@K}}{\text{DCG}_{\text{idéal}}@K} \quad (1.3)$$

Cette métrique est particulièrement adaptée à l'évaluation de la similarité produit et du cross-sell, où l'ordre d'affichage impacte directement le taux de clic de l'utilisateur.

1.7.1.3 Coverage

La couverture catalogue mesure la diversité des recommandations générées par le système :

$$\text{Coverage} = \frac{|\text{produits uniques recommandés}|}{|\text{catalogue}|} \quad (1.4)$$

Cette métrique est critique pour un catalogue fortement saisonnier comme celui de La Foir'Fouille : les nouveautés doivent apparaître dans les recommandations dès leur mise en ligne, et non être systématiquement écrasées par les bestsellers historiques.

1.7.2 Métriques online (perspectives)

Les métriques online nécessitent un déploiement en production et un dispositif de test A/B. Elles sont présentées ici comme perspectives de validation de l'impact business de la solution.

TABLE 1.9 – Métriques d'évaluation online et lien avec les objectifs

Métrique	Définition	Lien avec les objectifs
CTR	Taux de clic sur les recommandations affichées	Valide la pertinence perçue par l'utilisateur
CVR	Taux de conversion après clic sur une recommandation	Mesure directe de l'augmentation du taux de conversion
Panier moyen	Valeur moyenne du panier avec recommandations actives	Mesure de l'impact du cross-sell
Latence P95	95 ^e percentile du temps de réponse API	Conformité à la contrainte technique < 100 ms

1.7.3 Protocole d'évaluation offline

L'évaluation offline est conduite selon le protocole suivant, basé sur un split temporel des commandes SAP Commerce :

1. **Split temporel** : les commandes sont divisées en ensemble d'entraînement (80 % les plus anciennes) et ensemble de test (20 % les plus récentes), afin d'éviter toute fuite de données temporelles.
2. **Simulation** : pour chaque panier de l'ensemble de test, le système génère ses recommandations en utilisant uniquement les données d'entraînement.
3. **Calcul des métriques** : Precision@5, Recall@5, NDCG@5 et Coverage sont calculés par comparaison entre les recommandations générées et les achats réels de l'ensemble de test.
4. **Comparaison baseline** : les résultats sont comparés à une baseline de co-occurrence brute (sans correction par le lift) afin de quantifier l'apport de l'algorithme FP-Growth avec mesure de lift.

1.8 Planning et organisation du stage

1.8.1 Ordre de priorité des fonctionnalités

En cas de contrainte de temps, les fonctionnalités sont priorisées selon leur importance académique et leur valeur métier :

TABLE 1.10 – Priorité des fonctionnalités par ordre d'implémentation

Rang	Fonctionnalité	Complexité	Valeur
1	Top ventes (time-decay)	Faible	Forte (base de tout)
2	Cross-sell FP-Growth	Moyenne	Très forte (académique)
3	Similarité produit hybride	Élevée	Très forte (IA avancée)
4	Top ventes personnalisé	Moyenne	Forte (UX)
5	Saisonnalité backoffice	Faible	Moyenne (métier)